



PROJET DE FOUILLE DE DONNÉES

Système de Recommandation de Films

Fouille Tabulaire & Fouille de Graphes sur MovieLens
Small

Dataset	MovieLens Small — ~100 836 notes, 610 utilisateurs, 9 724 films
Algorithmes	K-Means, Clustering Hiérarchique (Ward), PageRank, Louvain
Bibliothèques	pandas, scikit-learn, networkx, python-louvain, matplotlib, seaborn
Langage	Python 3.9+ Jupyter Notebook

Elaboré par :

Jlassi Safa & Boujemaa Ines

Encadré par :

Mr. Mezni Haythem

Faculté des Sciences Juridiques, Économiques et Gestion de Jendouba

1.Introduction

Les systèmes de recommandation sont au cœur de nombreuses applications modernes — e-commerce, plateformes de streaming, réseaux sociaux — en permettant de personnaliser l'expérience utilisateur à grande échelle. Ce projet s'inscrit dans le cadre du cours de Fouille de Données et vise à construire un système de recommandation de films en exploitant deux approches complémentaires :

- **Fouille de données tabulaires** : regroupement (clustering) des utilisateurs par leurs profils de notation, avec deux algorithmes — K-Means et Clustering Hiérarchique Agglomératif.
- **Fouille de graphes** : modélisation des interactions utilisateur-film sous forme de graphe biparti, analyse de centralité, PageRank et détection de communautés (Louvain).

Le dataset utilisé est **MovieLens Small** (GroupLens Research, Université du Minnesota), un jeu de données de référence en recherche sur la recommandation. Le notebook complet est disponible dans le dépôt GitHub du projet.

1.1 Objectifs

- Appliquer et interpréter des algorithmes de clustering sur des données de notation.
- Transformer des données tabulaires en graphe et en extraire des informations structurales.
- Comparer les deux approches et proposer une logique de recommandation argumentée.
- Identifier l'algorithme de clustering offrant les meilleurs résultats.

1.2 Organisation du rapport

Section 2 — description du dataset et EDA ; Section 3 — méthodologie et choix algorithmiques ; Section 4 — résultats et recommandations ; Section 5 — conclusion, limites et perspectives.

2. Description du Dataset

2.1 Source et structure

Le dataset **MovieLens Small** (ml-latest-small) est publié et maintenu par GroupLens Research (Université du Minnesota). Il est librement accessible sur <https://grouplens.org/datasets/movielens/latest/>. Ce dataset constitue une référence standard dans la littérature sur les systèmes de recommandation.

Fichier	Colonnes	Description
ratings.csv	userId, movieId, rating, timestamp	100 836 notes de 0.5 à 5.0 (pas de 0.5)
movies.csv	movieId, title, genres	9 742 films avec titre et genres pipe-séparés
tags.csv	userId, movieId, tag, timestamp	Tags libres — non utilisé dans ce projet

2.2 Statistiques clés

Indicateur	Valeur
Utilisateurs uniques	610
Films uniques notés	9 724
Nombre total de notes	100 836
Note moyenne	3.50 / 5.0
Plage des notes	0.5 → 5.0 (pas de 0.5)
Densité de la matrice	~1.70 % (très creuse)
Notes par utilisateur (médiane)	~70
Films les plus notés	Forrest Gump, Pulp Fiction, Shawshank Redemption...

2.3 Analyse Exploratoire des Données (EDA)

Observations issues de l'EDA :

- **Distribution des notes asymétrique** : les notes 4.0 et 3.0 sont les plus fréquentes, témoignant d'un biais de positivité classique.
- **Déséquilibre du nombre de notes par utilisateur** : quelques utilisateurs hyperactifs ont noté plusieurs centaines de films tandis que la majorité en a noté moins de 100.
- **Matrice très creuse (~1.70 %)** : ce qui justifie l'utilisation de la SVD tronquée (30 composantes) pour réduire la dimensionnalité avant le clustering.
- **Genres les plus représentés** : Drama, Comedy, Thriller et Action.




Figure 1 — EDA : Distribution des notes (gauche), Notes par utilisateur (centre), Top 20 films les plus notés (droite)

3. Méthodologie

3.1 Préparation des données

Les fichiers **ratings.csv** et **movies.csv** sont chargés avec pandas puis fusionnés sur la clé *movieId*. Aucun doublon ni valeur manquante n'a été détecté. Une matrice pivot utilisateurs × films est construite à partir du dataframe fusionné.

Trois transformations successives sont appliquées avant le clustering :

- **Centrage par utilisateur** : soustraction de la note moyenne de chaque utilisateur pour neutraliser le biais de sévérité/générosité.
- **SVD tronquée (30 composantes, scikit-learn)** : réduction dimensionnelle capturant les patterns latents. Les 30 composantes expliquent ~37.4 % de la variance sur cet espace réduit.
- **Normalisation L2 par ligne** : chaque vecteur utilisateur est projeté sur la sphère unité afin que K-Means se base sur la direction des préférences, pas leur amplitude.

3.2 Phase 1 — Clustering Tabulaire

Algorithme 1 — K-Means (scikit-learn, *n_init=20*, *max_iter=500*, *random_state=42*)

Le nombre optimal de clusters est déterminé par deux méthodes complémentaires :

- **Méthode Elbow** : l'inertie est tracée en fonction de *k* (2 à 10) ; on identifie le "coude" à partir duquel le gain marginal devient faible.
- **Score de silhouette** : mesure la cohésion intra-cluster et la séparation inter-cluster. Un score proche de 1 indique des clusters bien définis.

Le *k* final est contraint à un minimum de 4 pour garantir des clusters informatifs, même si la silhouette brute est maximale pour *k*=2 (silhouette=0.0985).




Figure 2 — Méthode Elbow (inertie, gauche) et Score de Silhouette (droite) pour *k*=2 à *k*=10

Algorithme 2 — Clustering Hiérarchique Agglomératif (linkage=Ward)

La méthode de Ward minimise la variance intra-cluster à chaque fusion, ce qui en fait l'équivalent hiérarchique de K-Means. Un dendrogramme sur un sous-échantillon de 50 utilisateurs permet de visualiser la structure hiérarchique des fusions.

Logique de recommandation par cluster

Pour un utilisateur cible : (1) on identifie son cluster, (2) on calcule la note moyenne de chaque film au sein du cluster (parmi les autres membres), (3) on filtre les films ayant moins de 5 votes, (4) on retourne les 8 films les mieux notés non encore vus par l'utilisateur.

3.3 Phase 2 — Fouille de Graphes

Construction du graphe biparti

Un graphe *G* est construit avec **networkx**. Chaque nœud est soit un utilisateur (préfixe "u_") soit un film (préfixe "m_"). Une arête (utilisateur, film) est créée si la note est ≥ 3.5 , avec poids = note réelle. Le graphe est restreint

aux 200 utilisateurs les plus actifs pour des raisons de performance.

Résultat : **7 286 nœuds** (200 users + 7 086 films), **47 886 arêtes**, densité = 0.00180.

Techniques appliquées

- **Centralité de degré et betweenness (networkx)** : identification des films "hubs" les plus connectés.
- **PageRank (alpha=0.85, pondéré par les notes)** : classement des films par importance structurelle.
- **Détection de communautés — Algorithme de Louvain (python-louvain)** : partition du graphe en communautés maximisant la modularité.

Logique de recommandation par graphe

Pour un utilisateur cible : (1) on identifie sa communauté Louvain, (2) on sélectionne les films de cette communauté non encore notés par l'utilisateur, (3) on les trie par score PageRank décroissant.

4. Résultats

4.1 Résultats du Clustering K-Means

Bien que $k=2$ maximise le score de silhouette (0.0985), ce choix produirait des clusters trop pauvres et peu informatifs. Nous avons donc retenu $k=4$ (silhouette=0.0725) afin d'obtenir une segmentation plus riche et exploitable. Ce choix est pédagogique et vise à équilibrer qualité et interprétabilité

k	Score Silhouette	Inertie	Distribution des clusters
2	0.0985 ★	460	325 / 285
3	0.0670	430	255 / 156 / 199
4	0.0725 ✓	409	164 / 120 / 140 / 186
5	0.0745	393	128 / 94 / 114 / 113 / 161
6	0.0771	381	94 / 142 / 116 / 66 / 97 / 95
10	0.0700	355	39 / 54 / 104 / 63 / 77 / 37 / 80 / 40 / 69 / 47

Note : les scores de silhouette restent modérés (< 0.1), ce qui est attendu compte tenu de la forte sparsité initiale et de la réduction SVD. Cela ne traduit pas une mauvaise qualité du clustering mais reflète la nature continue des préférences utilisateurs.




Figure 3 — Visualisation des 4 clusters K-Means projetés en 2D via PCA (610 utilisateurs, composantes principales 1 et 2)

4.2 Recommandations K-Means — Utilisateur 1 (Cluster 1)

L'utilisateur 1 est assigné au **Cluster 1**. Les recommandations suivantes sont générées parmi les films non encore vus ayant reçu au moins 5 votes dans le cluster :

#	Titre du film	Note moy. cluster	Nb votes
1	Paths of Glory (1957)	4.90	5
2	All About My Mother (Todo sobre mi madre) (1999)	4.81	8
3	Secrets & Lies (1996)	4.75	8
4	Hoop Dreams (1994)	4.71	12
5	Streetcar Named Desire, A (1951)	4.71	12

6	Nausicaä of the Valley of the Wind (1984)	4.70	5
7	Verdict, The (1982)	4.70	5
8	Double Indemnity (1944)	4.69	8





Figure 4 — Top recommandations K-Means pour l'utilisateur 1 (Cluster 1)

4.3 Résultats du Clustering Hiérarchique (Ward, k=4)

Le clustering hiérarchique avec liaison Ward est appliqué avec k=4. Score de silhouette : **0.0256** (inférieur à K-Means). Distribution : 255 / 96 / 157 / 102 utilisateurs.



4.4 Recommandations Hiérarchiques — Utilisateur 1 (Cluster 2)

#	Titre du film	Note moy. cluster	Nb votes
1	Paths of Glory (1957)	4.83	6
2	Secrets & Lies (1996)	4.75	8
3	Lawrence of Arabia (1962)	4.69	27
4	Last Picture Show, The (1971)	4.67	6
5	Hoop Dreams (1994)	4.67	12
6	Bicycle Thieves (Ladri di biciclette) (1948)	4.61	9
7	Double Indemnity (1944)	4.60	10
8	Celebration, The (Festen) (1998)	4.58	6

4.5 Comparaison K-Means vs Clustering Hiérarchique




Figure 6 — Comparaison des recommandations K-Means (gauche) vs Hiérarchique (droite) pour l'utilisateur 1. Films communs aux deux méthodes : Paths of Glory, Secrets & Lies, Hoop Dreams, Double Indemnity.

Critère	K-Means ★	Hiérarchique (Ward)
Score de silhouette (k=4)	0.0725	0.0256
Temps d'exécution	0.30 s	0.03 s
Méthode de liaison	Centroïdes	Ward
Interprétabilité	Centroïdes clairs	Dendrogramme visuel
Nécessite k prédéfini	Oui	Oui
Sensibilité initialisation	Faible (n_init=20)	Aucune (déterministe)
Dendrogramme disponible	Non	Oui
Films communs (user 1)	4 / 8 films	4 / 8 films

★ **Conclusion clustering** : K-Means obtient un score de silhouette nettement supérieur (0.0725 vs 0.0256). Il est choisi comme algorithme de référence. Le clustering hiérarchique apporte une valeur ajoutée complémentaire via le dendrogramme.

4.6 Résultats de la Fouille de Graphes

Le graphe biparti construit contient **7 286 nœuds** (200 utilisateurs + 7 086 films) et **47 886 arêtes** (notes ≥ 3.5), avec une densité de 0.00180. **9 communautés** ont été détectées par l'algorithme de Louvain (modularité = 0.2714).

Films les plus centraux — Degree Centrality et PageRank

Ran g	Titre du film	Degree Centrality	Betweennes s	PageRank
1	Matrix, The (1999)	0.01894	0.00593	0.001129
2	Forrest Gump (1994)	0.01826	0.00444	0.001081
3	Star Wars: Episode IV - A New Hope (1977)	0.01798	0.00565	0.001062
4	Pulp Fiction (1994)	0.01743	0.00494	0.001066
5	Shawshank Redemption, The (1994)	0.01716	0.00459	0.001052
6	Star Wars: Episode V (1980)	0.01688	0.00440	0.001005
7	Silence of the Lambs, The (1991)	0.01634	0.00590	0.000993
8	Fight Club (1999)	0.01606	0.00471	0.000965
9	Raiders of the Lost Ark (1981)	0.01565	0.00437	0.000917
10	Star Wars: Episode VI - Return of the Jedi	0.01551	0.00429	0.000914




Figure 7 — Top 15 films par Degree Centrality (hubs du graphe biparti)

On observe que Matrix (1999), Forrest Gump (1994) et Pulp Fiction (1994) apparaissent systématiquement parmi les films les plus centraux et influents, confirmant leur rôle de hubs majeurs dans le réseau.

Détection de communautés (Louvain) — 9 communautés

Communauté	Nœuds	Communauté	Nœuds
0	1 008	5	238
1	2 459	6	442
2	690	7	239
3	72	8	207
4	1 931	—	—




Figure 8 — Sous-graphe biparti : films centraux (rouge/hubs) et leurs utilisateurs (bleu). Les 5 films les plus connectés du graphe sont clairement identifiés comme hubs centraux.

Recommandations par graphe — Utilisateur 1 (Communauté 0)

#	Titre du film	PageRank	Degree Centrality
1	Pulp Fiction (1994)	0.001066	0.01743
2	Shawshank Redemption, The (1994)	0.001052	0.01716
3	Godfather, The (1972)	0.000910	0.01455
4	Lord of the Rings: The Fellowship of the Ring (2001)	0.000843	0.01414
5	Lord of the Rings: The Return of the King (2003)	0.000817	0.01400
6	Sixth Sense, The (1999)	0.000794	0.01373
7	Lord of the Rings: The Two Towers (2002)	0.000792	0.01359
8	Memento (2000)	0.000790	0.01290

4.7 Comparaison Globale : Clustering vs Graphe

Les recommandations des deux approches pour l'utilisateur 1 sont **entièrement complémentaires** (0 film en commun). Le clustering propose des films d'auteur peu connus très bien notés par des utilisateurs similaires, tandis que l'approche graphe recommande des blockbusters critiquement reconnus.

Critère	Clustering (K-Means)	Graphe (Louvain + PageRank)
Base de recommandation	Profils de notation similaires	Importance structurelle dans le réseau
Type de films suggérés	Films d'auteur très bien notés	Blockbusters influents / bien notés
Interprétabilité	Élevée (note moy. du cluster)	Modérée (PageRank moins intuitif)
Chevauchement (user 1)	0 film en commun	0 film en commun
Sensibilité au bruit	Faible (min. 5 votes)	Faible (normalisation PageRank)
Scalabilité	Bonne (SVD préalable)	Limitée (graphe dense)
Diversité reco.	Modérée	Élevée (communautés variées)

→ Les deux approches sont **complémentaires** : le clustering recommande des films très bien notés par des utilisateurs au profil similaire (pertinence élevée), tandis que le graphe met en avant des films influents dans le réseau global (diversité et découverte). Une combinaison hybride serait optimale en production.

5. Conclusion

5.1 Bilan

Ce projet a mis en œuvre deux approches complémentaires de fouille de données pour la recommandation de films sur le dataset MovieLens Small. L'ensemble des livrables demandés a été produit :

- EDA complète avec statistiques descriptives et visualisations.
- Clustering avec deux algorithmes (K-Means et Hiérarchique Agglomératif), évaluation par silhouette et inertie, justification du nombre de clusters.
- Fouille de graphes avec trois techniques : centralité de degré, PageRank, détection de communautés (Louvain).
- Systèmes de recommandation fonctionnels pour les deux approches, avec exemples concrets.
- Comparaison détaillée K-Means vs Hiérarchique et Clustering vs Graphe.

K-Means se révèle supérieur au clustering hiérarchique sur ce dataset en termes de score de silhouette (0.0725 vs 0.0256) et est choisi comme référence. La logique de recommandation basée sur les clusters produit des suggestions pertinentes pour les utilisateurs aux goûts cinéphiles exigeants. La fouille de graphes ajoute une perspective complémentaire en identifiant des films influents dans les communautés, favorisant la diversité et la découverte.

5.2 Limites

- **Sparsité de la matrice** : avec seulement 1.7 % de la matrice remplie, les scores de silhouette restent faibles, limitant la confiance dans les clusters.
- **Cold start** : les deux approches ne peuvent pas recommander de films à un nouvel utilisateur sans historique de notes.
- **Scalabilité du graphe** : le graphe biparti complet est coûteux ; nous avons restreint aux 200 utilisateurs les plus actifs.
- **Absence de validation externe** : sans set de test, il est difficile d'évaluer objectivement la pertinence (pas de métriques Precision@k, Recall@k).

5.3 Perspectives

- **Filtrage collaboratif matriciel (ALS, SVD++)** : approche plus sophistiquée qui optimise directement la reconstruction de la matrice de notes.
- **Système hybride** : combiner le score cluster et le PageRank dans une fonction de recommandation unifiée.
- **Évaluation quantitative** : partage des données en train/test pour calculer Precision@10, Recall@10, NDCG.
- **Graphe de similarité film-film** : construire un graphe de similarité cosinus entre films pour des recommandations basées sur le contenu.

Références

- [1] F. Maxwell Harper and Joseph A. Konstan. *The MovieLens Datasets: History and Context*. ACM TIIS, 5(4), 2015. <https://grouplens.org/datasets/movielens/>
- [2] scikit-learn developers. *scikit-learn: Machine Learning in Python*. Pedregosa et al., JMLR 12, 2825-2830, 2011.
- [3] Aric A. Hagberg et al. *NetworkX: Network Analysis in Python*. <https://networkx.org>
- [4] Thomas Aynaud. *python-louvain: Louvain Community Detection*. <https://python-louvain.readthedocs.io>
- [5] Wes McKinney. *Data Structures for Statistical Computing in Python*. Proceedings SciPy 2 .
- [6] Vincent D. Blondel et al. *Fast unfolding of communities in large networks*. JSTAT, 2008.
- [7] Lawrence Page et al. *The PageRank Citation Ranking: Bringing Order to the Web*. Stanford InfoLab, 1999.
- [8] Certains extraits de code et suggestions méthodologiques ont été générés avec l'aide d'outils d'intelligence artificielle (Copilot, ChatGPT, Claude), puis adaptés et vérifiés manuellement.